

Bước 1: Import các thư viện cần thiết và đọc dữ liệu từ file csv.

```
# =====  
# 📦 Import các thư viện cần thiết cho Data Mining  
# =====  
  
# Xử lý dữ liệu  
import pandas as pd  
import numpy as np  
  
# Trực quan hóa dữ liệu  
import matplotlib.pyplot as plt  
import seaborn as sns  
  
# Tiền xử lý và mô hình hóa  
from sklearn.preprocessing import StandardScaler, LabelEncoder  
from sklearn.model_selection import train_test_split  
from sklearn.cluster import KMeans  
from sklearn.impute import SimpleImputer  
  
# Kiểm định và thống kê  
import scipy.stats as stats  
  
# Cảnh báo hiển thị  
import warnings  
warnings.filterwarnings('ignore')  
  
print("Import thư viện thành công!")
```

Import thư viện thành công!

Bước 2: Tải file lên Google Colab

```
from google.colab import files  
uploaded = files.upload()  
  
import pandas as pd  
import io  
  
df = pd.read_csv('listings_ready_change_01.csv')  
df.head()
```

No file chosen

Upload widget is only available when the cell has been executed in the current browser session. Please rerun this cell to enable.

Saving listings_ready_change_01.csv to listings_ready_change_01.csv

	listing_id	host_id	host_name	host_since	host_response_rate	host_acceptance_rate	host_is_superhost	host_experience	prop
0	2708.0	3008.0	Chas.	16/09/2008 0:00	1.0	1.00	t	17.0	Priv
1	2732.0	3041.0	Louise-Diane	17/09/2008 0:00	1.0	0.50	f	17.0	Priv
2	6931.0	3008.0	Chas.	16/09/2008 0:00	1.0	1.00	t	17.0	Priv
3	7874.0	21700.0	Henry	15/06/2009 0:00	1.0	0.98	t	16.0	Priv
4	8021.0	22460.0	Sherree Strong	20/06/2009 0:00	1.0	1.00	f	16.0	Priv

5 rows × 27 columns

Bước 3: Chuẩn hóa dữ liệu

a. Chuyển giá trị host_is_superhost từ t/f sang 1/0 và NULL sang 0.

```
# Chuyển t/f thành 1/0 và fill NA = 0  
df['host_is_superhost'] = df['host_is_superhost'].map({'t': 1, 'f': 0})
```

```
# Nếu có giá trị trống (NaN) → đưa về 0
df['host_is_superhost'] = df['host_is_superhost'].fillna(0).astype(int)

df['host_is_superhost'].value_counts()
```

```

count
host_is_superhost
0          7036
1          5736

```

dtype: int64

```
df['instant_bookable'] = df['instant_bookable'].map({'t': 1, 'f': 0})
df['instant_bookable'] = df['instant_bookable'].fillna(0).astype(int)
```

```
df['instant_bookable'].value_counts()
```

```

count
instant_bookable
0       10653
1        2119

```

dtype: int64

b. Loại bỏ các thuộc tính không cần thiết

```
cols_to_drop = ['latitude', 'longitude', 'last_scraped', 'first_review', 'last_review']

df = df.drop(columns=cols_to_drop)

df.head()
```

```

listing_id  host_id  host_name  host_since  host_response_rate  host_acceptance_rate  host_is_superhost  host_experience  prop
0      2708.0   3008.0    Chas.   16/09/2008          1.0          1.00          1          17.0  Priv
           0:00
1      2732.0   3041.0  Louise-   17/09/2008          1.0          0.50          0          17.0  Priv
           Diane  0:00
2      6931.0   3008.0    Chas.   16/09/2008          1.0          1.00          1          17.0  Priv
           0:00
3      7874.0  21700.0    Henry   15/06/2009          1.0          0.98          1          16.0  Priv
           0:00
4      8021.0  22460.0  Sherree   20/06/2009          1.0          1.00          0          16.0  Priv
           Strong  0:00

```

5 rows × 22 columns

Xóa những dòng mà 2 cột bị NULL

```
df = df.dropna(subset=['host_id', 'listing_id'])
```

Bước 4: Thống kê mô tả

```
df.describe().transpose()
```

	count	mean	std	min	25%	50%	75%	max
listing_id	11996.0	3.540263e+15	4.438808e+16	2708.00	15718024.50	32803613.00	4.670289e+07	5.990000e+17
host_id	11996.0	1.027958e+08	1.196026e+08	2410.00	11557647.00	48281579.00	1.566958e+08	6.811387e+08
host_response_rate	10034.0	9.471477e-01	1.766817e-01	0.00	1.00	1.00	1.000000e+00	1.000000e+00
host_acceptance_rate	10139.0	8.433327e-01	2.497004e-01	0.00	0.80	0.97	1.000000e+00	1.000000e+00
host_is_superhost	11996.0	4.781594e-01	4.995436e-01	0.00	0.00	0.00	1.000000e+00	1.000000e+00
host_experience	11996.0	9.491747e+00	2.714084e+00	0.00	8.00	10.00	1.100000e+01	1.700000e+01
accommodates	11996.0	3.787429e+00	2.697164e+00	1.00	2.00	3.00	5.000000e+00	1.600000e+01
bathrooms	11992.0	1.545113e+00	1.172638e+00	0.00	1.00	1.00	2.000000e+00	2.400000e+01
bedrooms	11979.0	1.619501e+00	1.294106e+00	0.00	1.00	1.00	2.000000e+00	2.400000e+01
beds	11951.0	2.151954e+00	1.666607e+00	0.00	1.00	2.00	3.000000e+00	3.200000e+01
instant_bookable	11996.0	1.765589e-01	3.813108e-01	0.00	0.00	0.00	0.000000e+00	1.000000e+00
price	11996.0	2.827757e+02	6.309915e+02	7.00	93.00	146.00	2.570000e+02	2.105300e+04
availability_365	11996.0	2.426176e+02	1.080926e+02	1.00	162.00	268.00	3.440000e+02	3.650000e+02
number_of_reviews	11996.0	9.089238e+01	1.333651e+02	0.00	7.00	36.00	1.260000e+02	3.119000e+03
reviews_per_month	10897.0	1.291803e+00	1.633658e+00	0.01	0.19	0.60	1.890000e+00	4.873000e+01
review_scores_rating	10897.0	4.807476e+00	2.906363e-01	1.00	4.75	4.89	4.970000e+00	5.000000e+00

```

import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# Tính phần trăm missing value của từng cột
missing_percent = df.isnull().mean() * 100
missing_percent = missing_percent.sort_values(ascending=False)

# Tính missing trung bình
avg_missing = missing_percent.mean()

plt.figure(figsize=(12, 8))
sns.barplot(
    x=missing_percent.values,
    y=missing_percent.index,
    palette="Blues_r"
)


# Ghi phần trăm lên từng thanh
for i, v in enumerate(missing_percent.values):
    plt.text(v + 0.5, i, f"{v:.2f}%", va='center')

plt.title("Missing values (%) for each column", fontsize=16)
plt.xlabel("Missing Percentage (%)")
plt.ylabel("Columns")

# Vẽ dòng average missing rate khi cần
plt.axvline(avg_missing, color='gray', linestyle='--')
plt.text(avg_missing + 0.5, len(missing_percent)-1,
         f"Avg missing: {avg_missing:.2f}%", fontsize=12, color='gray')

plt.tight_layout()
plt.show()

```



Bắt đầu lập trình hoặc [tạo](#) mã bằng trí tuệ nhân tạo (AI).

Mô tả số lượng host tham gia qua mỗi năm

```
import pandas as pd
import matplotlib.pyplot as plt

# 1. Chuyển ngày đúng định dạng
df['host_since'] = pd.to_datetime(df['host_since'], errors='coerce', dayfirst=True)

# 2. Lấy năm
df['host_since_year'] = df['host_since'].dt.year

# 3. Đếm host theo năm
hosts_per_year = df.groupby('host_since_year')['host_id'].nunique()

# 4. Vẽ biểu đồ
plt.figure(figsize=(14,7))
bars = plt.bar(hosts_per_year.index, hosts_per_year.values, color='skyblue')

plt.title("Số lượng host tham gia qua từng năm", fontsize=18)
plt.xlabel("Năm", fontsize=14)
plt.ylabel("Số host", fontsize=14)
plt.grid(axis='y', linestyle='--', alpha=0.5)


# 5. Thêm số lên đầu từng cột
for bar in bars:
    height = bar.get_height()
    plt.text(
        bar.get_x() + bar.get_width()/2,
        height + 10,          # vị trí cao hơn đầu cột
        f"{int(height)}",     # số hiển thị
    )
```

```

        ha='center', va='bottom',
        fontsize=11
    )

plt.tight_layout()
plt.show()

```



```

import matplotlib.pyplot as plt
import numpy as np
import seaborn as sns

# Set style đẹp
sns.set_theme(style="whitegrid")

# Calculate Total Hosts by group
hosts_by_group = df.groupby('neighbourhood_group_cleansed')['host_id'].nunique()

# Calculate Superhosts by group
superhosts_by_group = df[df['host_is_superhost'] == 1].groupby('neighbourhood_group_cleansed')['host_id'].nunique()

# Chuẩn bị dữ liệu
summary = pd.DataFrame({
    'Total Hosts': hosts_by_group,
    'Superhosts': superhosts_by_group
}).fillna(0)

summary = summary.sort_values('Total Hosts', ascending=False)

# Setup bar positions
x = np.arange(len(summary.index))
width = 0.35

# Tạo figure to đẹp
plt.figure(figsize=(16, 8))

# Màu sắc gradient đẹp hơn

```

```

colors_total = sns.color_palette("Blues_r", 3)[0]
colors_super = sns.color_palette("Oranges", 3)[1]

# Vẽ biểu đồ
bars1 = plt.bar(x - width/2, summary['Total Hosts'], width,
               label='Total Hosts', color=colors_total, edgecolor='black')

bars2 = plt.bar(x + width/2, summary['Superhosts'], width,
               label='Superhosts', color=colors_super, edgecolor='black')

# Title + font
plt.title("So sánh số lượng Host và Superhost theo từng vùng", fontsize=18, fontweight='bold', pad=20)
plt.xlabel("Khu vực (neighbourhood_group_cleansed)", fontsize=14)
plt.ylabel("Số lượng Host", fontsize=14)

# Xoay nhãn vùng
plt.xticks(x, summary.index, rotation=20, ha='right', fontsize=12)

# Hiển thị số trên từng cột
for bar in bars1:
    height = bar.get_height()
    plt.text(bar.get_x() + bar.get_width()/2, height + 20, int(height),
            ha='center', fontsize=11, color='black')


for bar in bars2:
    height = bar.get_height()
    plt.text(bar.get_x() + bar.get_width()/2, height + 20, int(height),
            ha='center', fontsize=11, color='black')

# Legend đẹp
plt.legend(title="Loại", fontsize=12, title_fontsize=13, loc='upper right')

# Tăng padding để bố cục đẹp hơn
plt.tight_layout()

plt.show()

```



```
import matplotlib.pyplot as plt
import seaborn as sns

sns.set_theme(style="whitegrid")

# Calculate the number of listings by neighbourhood_group_cleansed
listings_by_group = df['neighbourhood_group_cleansed'].value_counts()

# Sắp xếp giảm dần cho đẹp
listings_by_group = listings_by_group.sort_values(ascending=False)


plt.figure(figsize=(14, 7))
colors = sns.color_palette("viridis", len(listings_by_group))

bars = plt.bar(listings_by_group.index, listings_by_group.values, color=colors, edgecolor='black')

plt.title("Số lượng listing theo từng neighbourhood_group_cleansed", fontsize=18, fontweight='bold')
plt.xlabel("Khu vực", fontsize=14)
plt.ylabel("Số lượng listing", fontsize=14)
plt.xticks(rotation=20, ha='right')

# Ghi số lên thanh
for bar in bars:
    height = bar.get_height()
    plt.text(bar.get_x() + bar.get_width()/2, height + 10, int(height),
             ha='center', fontsize=12)

plt.tight_layout()
plt.show()
```



```
import matplotlib.pyplot as plt
import seaborn as sns

sns.set_theme(style="whitegrid")

# Calculate the average price by room type
avg_price_by_room = df.groupby('room_type')['price'].mean()

avg_price_by_room = avg_price_by_room.sort_values(ascending=False)


plt.figure(figsize=(10, 6))
colors = sns.color_palette("coolwarm", len(avg_price_by_room))

bars = plt.bar(avg_price_by_room.index, avg_price_by_room.values,
               color=colors, edgecolor='black')

plt.title("Giá trung bình của từng loại phòng", fontsize=18, fontweight='bold')
plt.xlabel("Loại phòng", fontsize=14)
plt.ylabel("Giá trung bình (USD)", fontsize=14)

# Hiển thị giá lên từng cột
for bar in bars:
    height = bar.get_height()
    plt.text(bar.get_x() + bar.get_width()/2, height + 2,
             f"${height:.2f}", ha="center", fontsize=12)

plt.xticks(rotation=15)
plt.tight_layout()
plt.show()
```



```
avg_price_by_host_type = df.groupby('host_is_superhost')['price'].mean().round(2)
avg_price_by_host_type
avg_listing_price = pd.DataFrame({
    "Host Type": ["Normal Host", "Superhost"],
    "Average Listing Price": [
        avg_price_by_host_type.loc[0],
        avg_price_by_host_type.loc[1]
    ]
})

avg_listing_price
import matplotlib.pyplot as plt
import seaborn as sns

sns.set_theme(style="whitegrid")
plt.figure(figsize=(8,6))

labels = ["Normal Host", "Superhost"]
values = avg_listing_price["Average Listing Price"]

colors = ["skyblue", "orange"]


bars = plt.bar(labels, values, color=colors, edgecolor="black")

plt.title("Giá trung bình của listing thuộc Superhost vs Host thường",
          fontsize=16, fontweight="bold")
plt.ylabel("Giá trung bình (USD)", fontsize=14)

# Ghi giá lên cột
for bar in bars:
    height = bar.get_height()
    plt.text(bar.get_x() + bar.get_width()/2, height + 2,
             f"${height}", ha="center", fontsize=12)

plt.tight_layout()
plt.show()
```

Giá trung bình của listing thuộc Superhost vs Host thường



```
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np

# Select only numeric columns for correlation calculation
numeric_df = df.select_dtypes(include=np.number)

# Calculate and plot the correlation matrix
plt.figure(figsize=(15, 10))
sns.heatmap(numeric_df.corr(), annot=True, cmap='coolwarm', fmt=".2f", linewidths=.5)
plt.title('Ma trận tương quan của các biến số số học', fontsize=18)
plt.show()
```

Ma trận tương quan của các biến số số học

